Predição de métricas de mídia digital

Pós Graduação - Ciência de Dados

IFSP - Campinas

Marcia Galeno, Rafael , Vinícius Nascimento

Contexto
AWS
Análise exploratória
Aprendizado de Máquina

Contexto

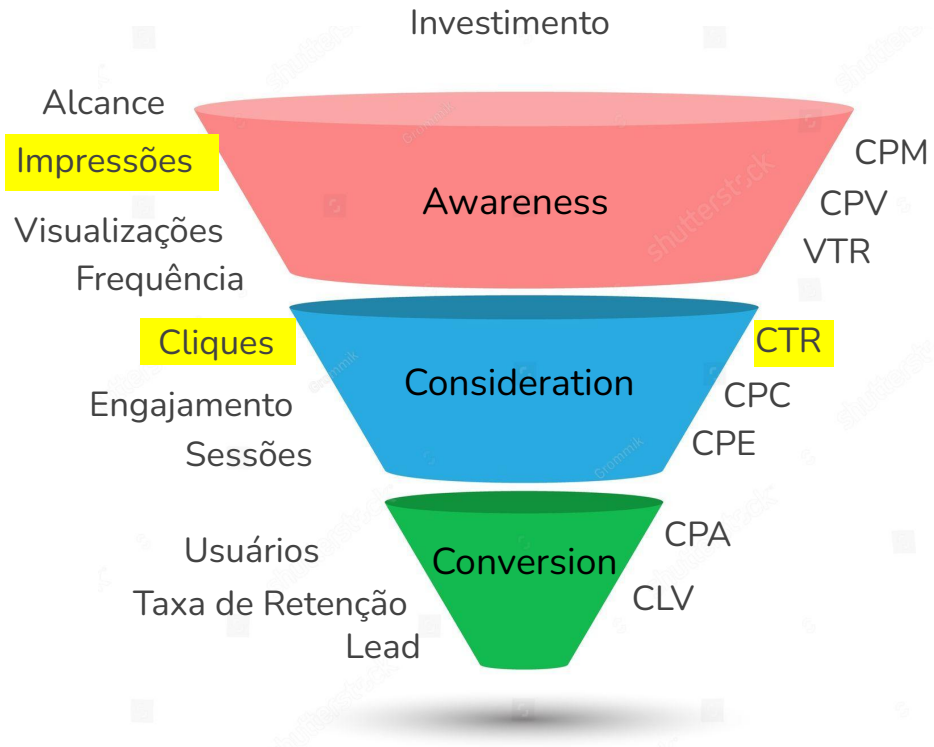

CTR = Cliques / Impressões

Veículo: Meta

Funil: Conversão

Formato: Story Display

Sem Influencer

alcance
conversão

Veículo: Tiktok

Funil: Awareness

Formato: Vídeo 10s

Sem Influencer

alcance
engajamento

AWS

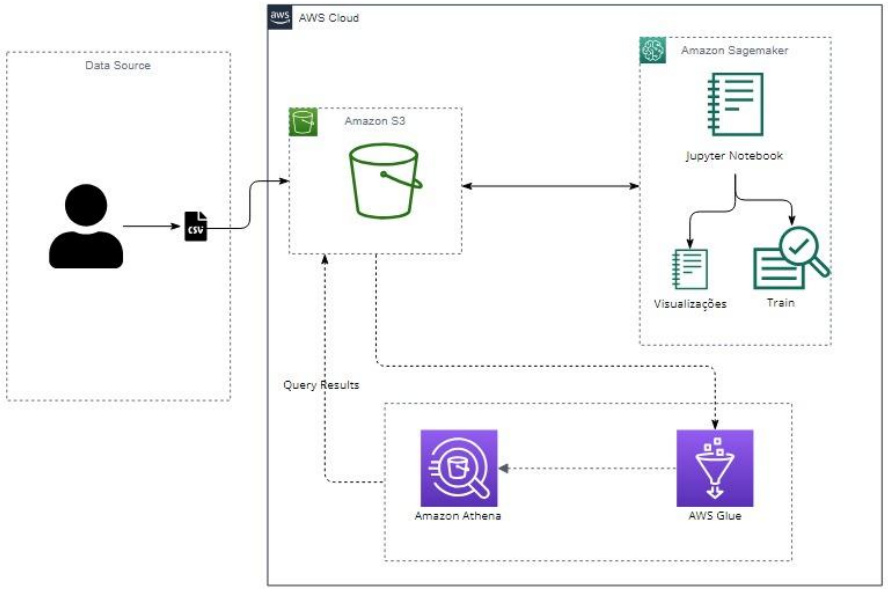
AWS Cloud
Data Source
csv
Amazon S3
Amazon Sagemaker
Jupyter Notebook
Visualizações
Train
Query Results
Amazon Athena
AWS Glue

Análise Exploratória

+R$ 92M
Investimento

+30B
Impressões

0,56%
CTR

+172M
Cliques

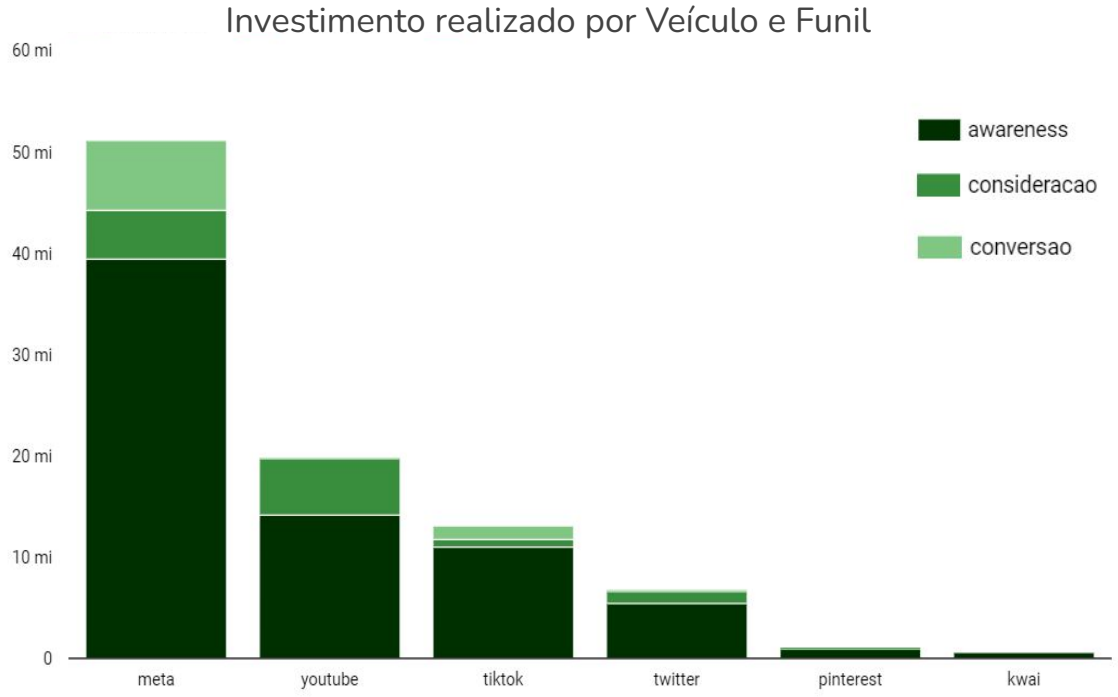

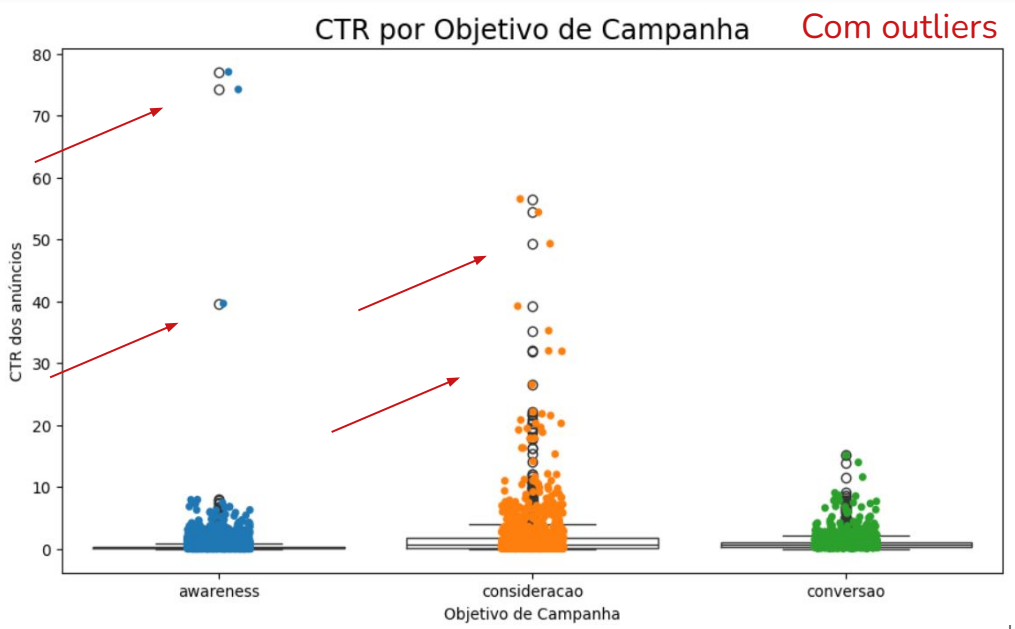

Com outliers

Muitos Outliers, que podem ter vindo de anúncios com engajamento orgânico ou baixo alcance.

Optamos pelo uso do Isolation Forest para identificar as anomalias que não se enquadram no padrão considerado normal da base.

Sem outliers

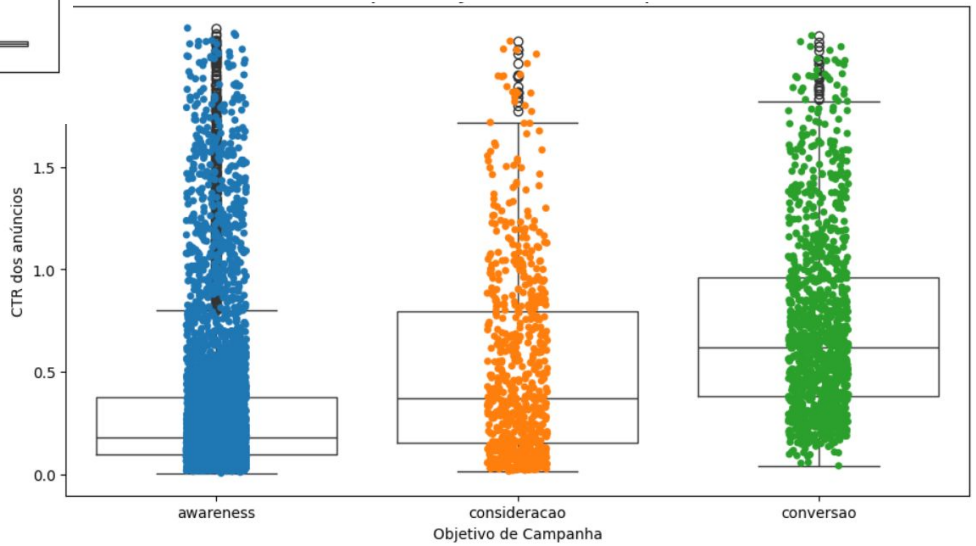

Consideração e Conversão têm CTR's maiores devido a segmentação do público.

Análise Exploratória

0,33%

CTR de anúncios com influencers

0,25%

CTR de anúncios sem influencers

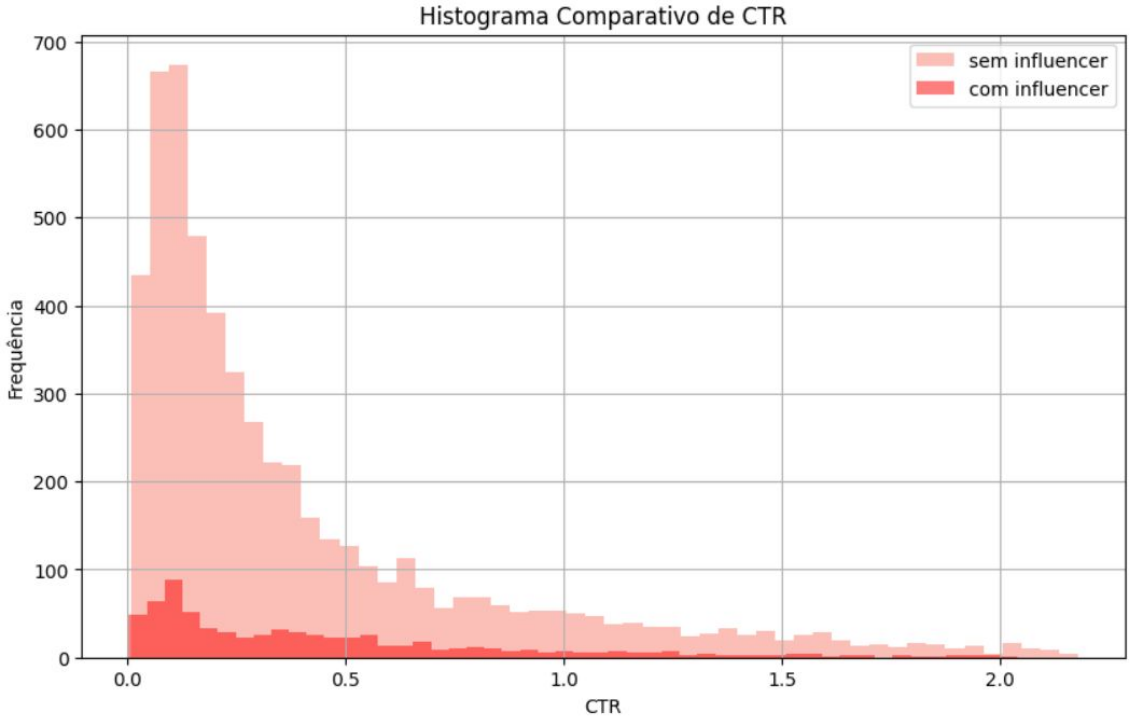

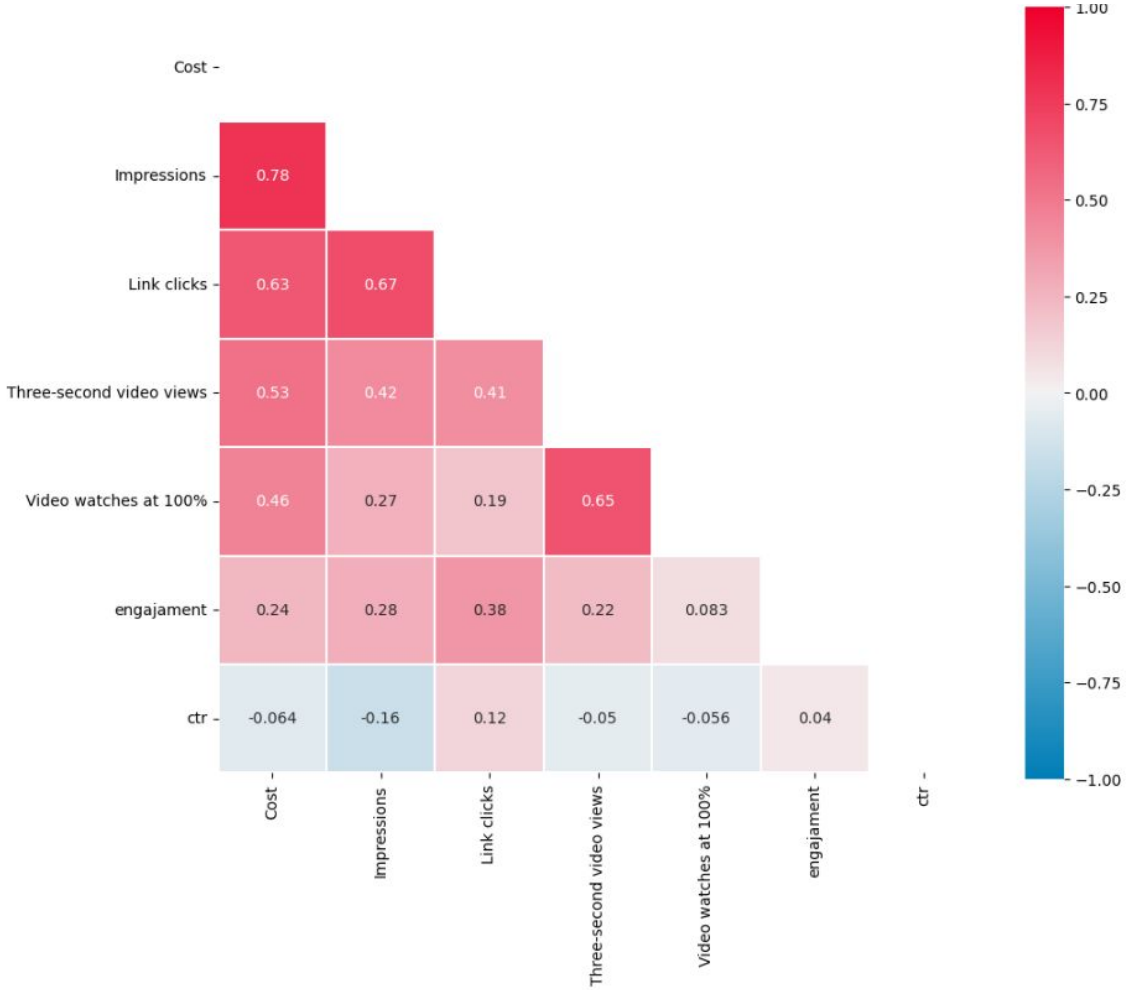

Considerando que o comportamento dos anúncios pode variar de funil para funil, ou veículo para veículo e o Investimento não é responsável pela oscilação do CTR, seria mais preciso predizer as Impressões e Cliques visto que possuem uma correlação mais forte.

Aprendizado de Máquina

Após a codificação dos dados categóricos com o Dummies do Pandas, excluímos uma coluna de cada categoria a fim de evitar o Dummy Variable Trap.

```
df2 = df_no_outliers.iloc[:,[0,1,2,9,10,11,12]] #criando uma nova base apenas com as colunas que vamos usar para o modelo.
#a partir daqui vamos codificar os dados categóricos da base usando o Dummies do Pandas.

col = ['funnel','channel','format']
df_encoded = pd.get_dummies(df2, columns=col) #criando novas colunas binárias a partir dos funis, canais e formatos.
```

```
col_for_del = 'funnel_awareness','channel_meta','format_video 15s'
for i in col_for_del:
    del df_encoded[i]
```

Dado o tamanho da base de cerca de 6 mil linhas, o conjunto de treinamento e teste foi dividido em 90/10.

Aprendizado de Máquina

Para os ajustes de hiperparâmetros optamos pela Bayes Search.

A otimização bayesiana é uma técnica baseada no teorema de Bayes, que descreve a probabilidade de ocorrência de um evento relacionado ao conhecimento atual. Quando isso é aplicado à otimização de hiperparâmetros, o algoritmo cria um modelo probabilístico a partir de um conjunto de hiperparâmetros que otimiza uma métrica específica. Ele usa análise de regressão para escolher iterativamente o melhor conjunto de hiperparâmetros.

A métrica escolhida para avaliação de desempenho dos modelos foi R^2.

Mesmo a normalização não sendo obrigatória em casos de regressão, optamos por simular o Random Forest na base com e sem o Robust Scaler. No Gradient Boosting não foi feita normalização.

ref : https://medium.com/analytics-vidhya/comparison-of-hyperparameter-tuning-algorithms-grid-search-random-search-bayesian-optimization-5326aaef1bd1

Aprendizado de Máquina

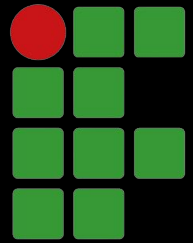

O modelo Random Forest processou dois target's simultaneamente quando atribuímos ao y uma lista.

```
bayes_rf_K.fit(X_ctr_treinamento, list(zip(y_clicks_treinamento,y_impressions_treinamento)))
```

O Gradient Boosting, por sua vez, exige o MultiOutputRegressor do Sklearn. No entanto, quando o unimos com o Bayes Search é necessário dividir os targets na busca pelos hiperparâmetros.

Random Forest Regressor

```
# Definição do espaço de busca para os hiperparâmetros
n_estimators = [10, 20, 30, 35, 40, 45, 50, 80, 90, 100, 150]
max_features = ['sqrt' , 'log2', None]
max_depth = [3, 5, 10, 13, 15]
min_samples_split = [2, 5, 10 , 13, 15]
min_samples_leaf = [1, 2, 3, 4 , 5]
bootstrap = [True, False]
```

Base sem Robust Scaler

```
Melhores Hiperparâmetros sem Kfold: OrderedDict([('bootstrap', True), ('max_depth', 15), ('max_features', None), ('min_samples_leaf', 3), ('min_samples_split', 10), ('n_estimators', 30)])
Melhores Hiperparâmetros com Kfold: OrderedDict([('bootstrap', True), ('max_depth', 13), ('max_features', None), ('min_samples_leaf', 5), ('min_samples_split', 15), ('n_estimators', 100)])
```

0.68	0.66	0.66	0.64
R^2 Clicks	R^2 Impressions	R^2 Clicks Kfold	R^2 Impressions Kfold

Base com Robust Scaler

```
Melhores Hiperparâmetros sem Kfold: OrderedDict([('bootstrap', True), ('max_depth', 15), ('max_features', None), ('min_samples_leaf', 4), ('min_samples_split', 10), ('n_estimators', 90)])
Melhores Hiperparâmetros com Kfold: OrderedDict([('bootstrap', True), ('max_depth', 5), ('max_features', None), ('min_samples_leaf', 5), ('min_samples_split', 10), ('n_estimators', 20)])
```

0.68	0.67	0.66	0.69
R^2 Clicks	R^2 Impressions	R^2 Clicks Kfold	R^2 Impressions Kfold

Gradient Boosting Regressor

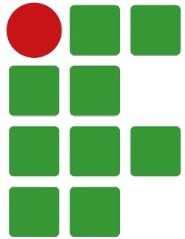

```
# Definição do espaço de busca para os hiperparâmetros
n_estimators = [ 50, 80, 90, 100, 150, 170, 180, 200]
learning_rate = [0.01 , 1.0, 'log-uniform']
max_features = ['sqrt' , 'log2', None]
max_depth = [3, 5, 10, 13, 15]
min_samples_split = [2, 5, 10 , 13, 15, 17]
min_samples_leaf = [1, 2, 3, 4 , 5, 7, 9]
```

Sem Kfold

```
Melhores Hiperparâmetros sem Kfold: OrderedDict([('learning_rate', 0.14170409680320734), ('max_depth', 13), ('max_features', 'sqrt'), ('min_samples_leaf', 7), ('min_samples_split', 2), ('n_estimators', 50)])
```

```
target Impressions sem Kfold: OrderedDict([('learning_rate', 0.13216840404382582), ('max_depth', 3), ('max_features', 'sqrt'), ('min_samples_leaf', 9), ('min_samples_split', 17), ('n_estimators', 200)])
```

0.75
R² Clicks

0.72
R² Impressions

Com Kfold

```
target Clicks: OrderedDict([('learning_rate', 0.2227573224949704), ('max_depth', 5), ('max_features', 'sqrt'), ('min_samples_leaf', 9), ('min_samples_split', 2), ('n_estimators', 50)])
```

```
target Impressions: OrderedDict([('learning_rate', 0.07852256558632155), ('max_depth', 15), ('max_features', 'log2'), ('min_samples_leaf', 7), ('min_samples_split', 13), ('n_estimators', 150)])
```

0.75
R² Clicks Kfold

0.73
R² Impressions Kfold

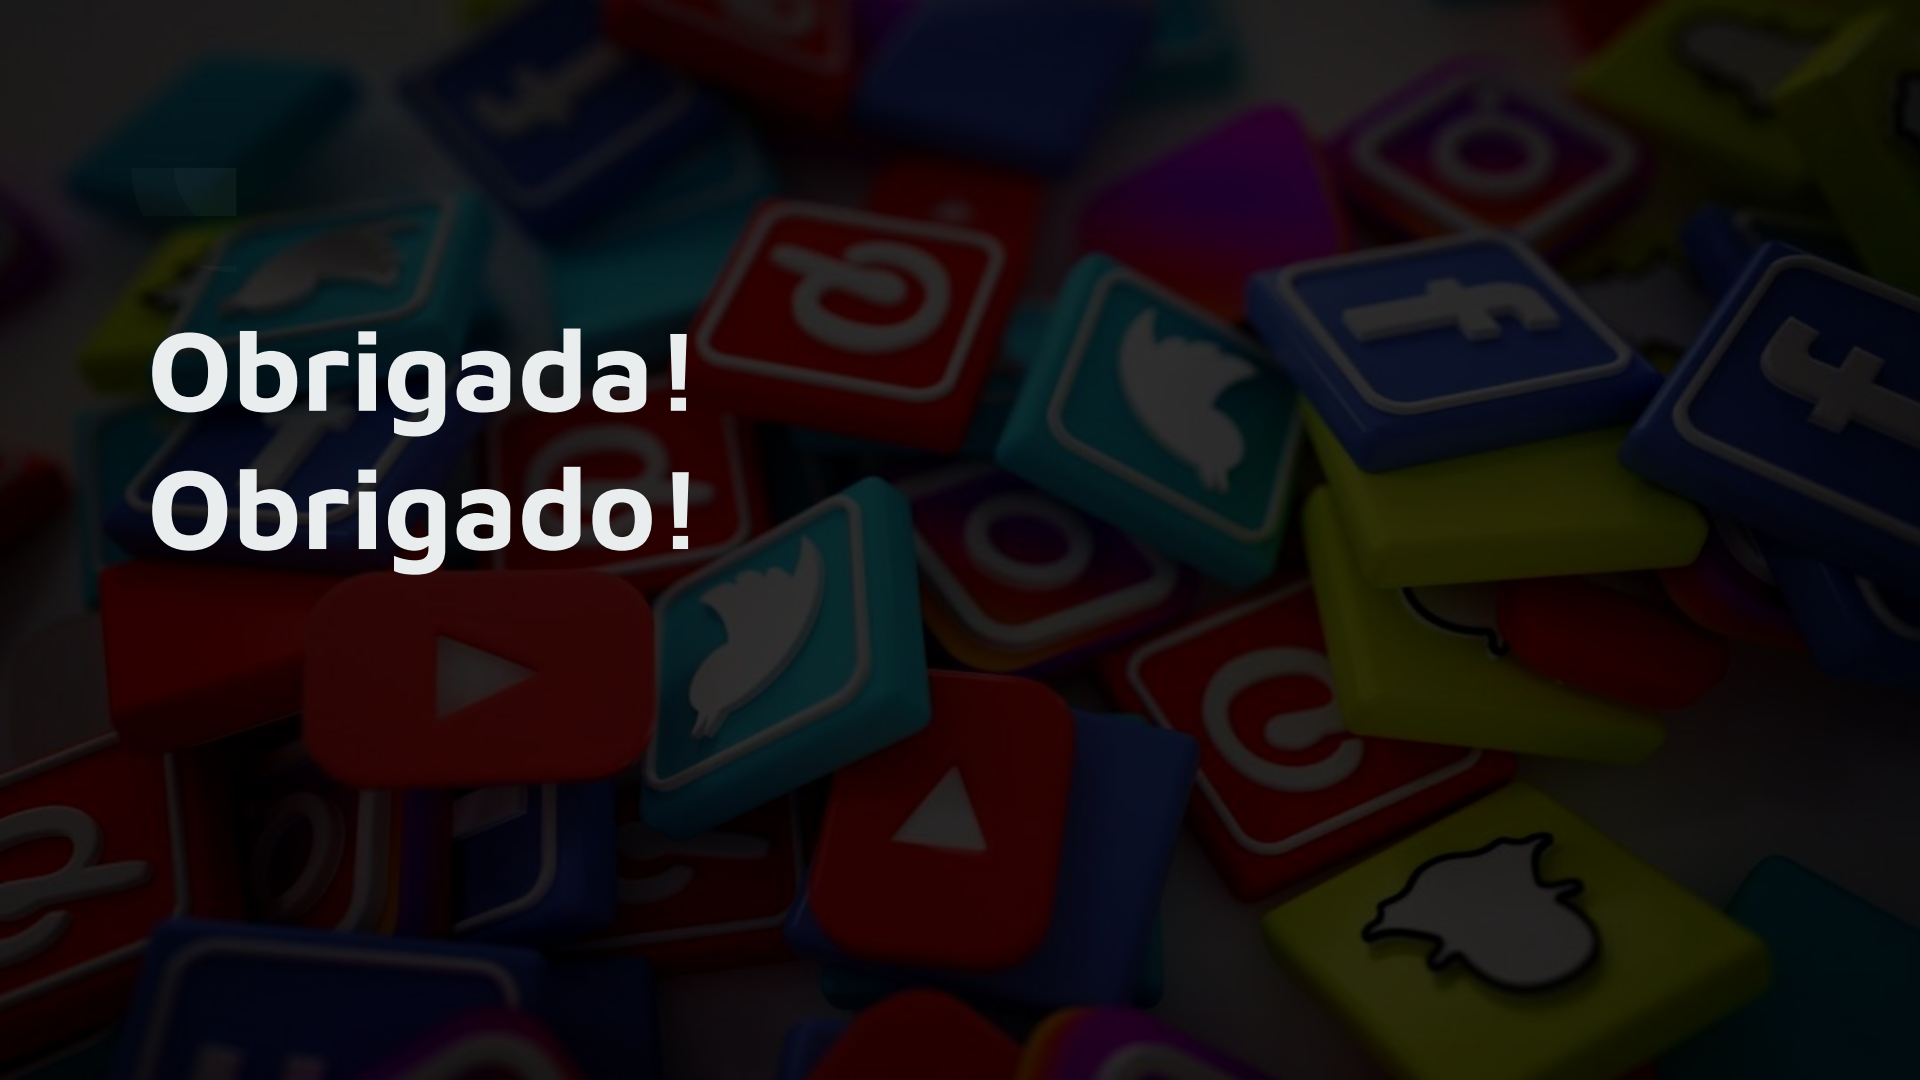
Obrigada!
Obrigado!